

Universidad Sergio Arboleda

Inteligencia Artificial

Optimización por Colonia de Hormigas

Taller de optimización combinatoria: el Agente Viajero

Integrantes:

Lina Castañeda

Jorge García

Brayan Hernandez

Docente:

Joaquin Sánchez

Bogotá D.C.

2026

Índice

1. Introducción	3
2. Descripción del problema	3
3. Punto 1. Formulación del problema	3
3.1. Variable de decisión	3
3.2. Función objetivo	3
3.3. Número de soluciones diferentes	4
3.4. Cálculo manual con un ejemplo pequeño	4
4. Punto 2. Diseño del algoritmo ACO	4
4.1. Variante y parámetros	4
4.2. Construcción de soluciones	5
4.3. Actualización de feromona	5
4.4. Mejora local 2-opt	5
4.5. Modos de ejecución	5
4.6. Qué significa el modo jerárquico, paso a paso	5
4.7. Complejidad	6
5. Punto 3. Implementación y comandos de ejecución	6
5.1. Estructura del repositorio	6
5.2. Compilación	7
5.3. Comandos de ejecución	7
5.4. Evidencia de ejecución	7
6. Punto 4. Evaluación experimental	8
6.1. Resultados	8
6.2. Análisis de las gráficas (Figura 2)	8
6.3. Análisis de resultados	9
6.4. Conclusión de la evaluación experimental	9

1. Introducción

La optimización por colonia de hormigas (*Ant Colony Optimization*, ACO) es una metaheurística inspirada en el comportamiento de las hormigas reales para encontrar caminos cortos entre su nido y las fuentes de alimento. Las hormigas artificiales construyen soluciones de forma probabilística guiadas por rastros de feromona y por información heurística del problema.

En este taller se diseñó e implementó un algoritmo ACO para resolver el problema del Agente Viajero (*Travelling Salesman Problem*, TSP). El objetivo no es solamente encontrar tours cortos, sino medir el desempeño del algoritmo en **tiempo** y en **memoria** para tres tamaños de instancia: 20, 2000 y 200000 ciudades, ejecutando todo en local.

La implementación se realizó en C++17 con paralelismo OpenMP y se publicó en el repositorio github.com/JAGR1792/ACO.

2. Descripción del problema

Se dispone de un conjunto de n ciudades con coordenadas en el plano. Se debe encontrar el recorrido cerrado más corto que visite cada ciudad exactamente una vez y regrese a la ciudad de origen.

Las instancias son euclidianas con puntos uniformes aleatorios en $[0, 1000]^2$, generadas con semilla fija (`-seed 42`) para que sean reproducibles. Se evaluaron tres tamaños:

Instancia	Ciudades	Semilla
Pequeña	20	42
Mediana	2000	42
Grande	200000	42

3. Punto 1. Formulación del problema

3.1. Variable de decisión

Una solución se representa como una permutación $\pi = (\pi_1, \pi_2, \dots, \pi_n)$ de las n ciudades, que indica el orden de visita. El tour es cerrado: después de π_n se regresa a π_1 .

3.2. Función objetivo

Se minimiza la distancia total del recorrido:

$$\text{mín } L(\pi) = \sum_{i=1}^{n-1} d(\pi_i, \pi_{i+1}) + d(\pi_n, \pi_1) \quad (1)$$

donde $d(a, b)$ es la distancia euclidiana entre las ciudades a y b .

3.3. Número de soluciones diferentes

Fijando la ciudad inicial y sin distinguir el sentido del recorrido, el número de tours diferentes es:

$$\frac{(n-1)!}{2} \quad (2)$$

Cuadro 1: Tamaño del espacio de búsqueda.

n	Tours diferentes
20	$\approx 6,1 \times 10^{16}$
2000	del orden de 10^{5735}
200000	intratable por enumeración

Por lo tanto, la enumeración exhaustiva solo es concebible para valores muy pequeños de n , lo que justifica el uso de una metaheurística como ACO.

3.4. Cálculo manual con un ejemplo pequeño

Con 4 ciudades $A(0,0)$, $B(3,0)$, $C(3,4)$, $D(0,4)$ existen $(4-1)!/2 = 3$ tours diferentes (fijando A como inicio):

Tour	Longitud
$A-B-C-D-A$	$3 + 4 + 3 + 4 = 14$
$A-B-D-C-A$	$3 + 5 + 3 + 5 = 16$
$A-C-B-D-A$	$5 + 4 + 5 + 4 = 18$

El óptimo es el tour $A-B-C-D-A$ con longitud 14. Este ejemplo muestra que la función objetivo es simplemente la suma de las aristas del recorrido cerrado.

4. Punto 2. Diseño del algoritmo ACO

4.1. Variante y parámetros

Se implementó la variante **MMAS** (*Max-Min Ant System*) simplificada con mejora local 2-opt. Sus parámetros fueron:

Cuadro 2: Configuración del algoritmo ACO.

Parámetro	Símbolo	Valor
Hormigas por iteración	m	20 (n=20), 25 (n=2000)
Iteraciones	$t_{\text{máx}}$	100 (n=20), 50 (n=2000)
Peso de feromona	α	1,0
Peso heurístico	β	2,5
Evaporación	ρ	0,1
Candidatos k-NN	k	8 (n=20), 25 (n=2000)

4.2. Construcción de soluciones

Cada hormiga construye un tour paso a paso. Estando en la ciudad i , la probabilidad de moverse a la ciudad no visitada j es proporcional a $\tau_{ij}^\alpha \cdot \eta_{ij}^\beta$, donde τ_{ij} es la feromona y $\eta_{ij} = 1/d_{ij}$ la información heurística.

Para no evaluar las n ciudades en cada paso se usa una **lista de candidatos**: solo se consideran las k vecinas más cercanas no visitadas (si ya se visitaron todas, se usa el resto). Esto reduce el costo por paso de $O(n)$ a $O(k)$.

4.3. Actualización de feromona

En cada iteración se evapora toda la feromona con factor $(1 - \rho)$ y solo la **mejor hormiga global** deposita feromona ($1/L_{\text{mejor}}$) en las aristas de su tour, con límites $[\tau_{\text{mín}}, \tau_{\text{máx}}]$ para evitar la convergencia prematura.

4.4. Mejora local 2-opt

Al mejor tour de cada iteración (y al mejor final) se le aplica 2-opt *first-improvement*: se prueba a reconectar pares de aristas y se acepta el primer intercambio que acorte el tour (ventana de 40 vecinos si $n > 500$).

4.5. Modos de ejecución

Cuadro 3: Modos del programa.

Modo	Uso	Descripción
full	$n \leq 5000$	ACO denso: matriz $n \times n$ + k-NN + MMAS + 2-opt
hier	n grande	Jerárquico: rejilla $\rightarrow$ ACO por celda $\rightarrow$ unión por centroides
nn	referencia	Vecino más cercano greedy (+ 2-opt si $n \leq 5000$)
auto	defecto	full si $n \leq 5000$, hier en otro caso

El modo **hier** es necesario para 200000 ciudades: una matriz densa de 200000^2 valores en **float** ocuparía ≈ 149 GB **por matriz** (el programa lo reporta como **matrix_mb_est**), imposible en local. En su lugar se particiona el plano en una rejilla de celdas de ≈ 600 puntos, se corre un ACO pequeño e independiente por celda y se concatenan los subtours ordenando las celdas por centroide.

4.6. Qué significa el modo jerárquico, paso a paso

hier significa que el problema grande se parte en problemas pequeños que sí caben en memoria, se resuelve cada uno con ACO y luego se pegan las soluciones. Concretamente, para $n = 200000$ y **-target-cluster 600**:

1. **Rejilla.** Se calcula $G = \lceil \sqrt{n/600} \rceil = 19$ y se divide el plano en una rejilla de 19×19 . Esto significa que el mapa queda cortado en cuadros iguales, como una cuadrícula.

2. **Celdas (clusters).** Cada ciudad cae en un cuadro según sus coordenadas. Los cuadros vacíos se descartan; en la ejecución quedaron 361 celdas con ≈ 550 ciudades cada una. Esto lo muestra la línea `[hier] n=200000 G=19 clusters=361`: G es el lado de la rejilla y `clusters` las celdas no vacías.
3. **ACO por celda.** Cada celda se resuelve como un TSP independiente con el mismo algoritmo MMAS + 2-opt, pero en pequeño: ≈ 10 hormigas, 15–25 iteraciones y $k = 15$ candidatos. Esto significa que cada celda usa matrices de $\approx 600 \times 600$ ($\approx 1,4$ MB) en vez de una matriz global de 200000×200000 . Las celdas se resuelven en paralelo con OpenMP.
4. **Orden de las celdas.** Se calcula el centroide (punto promedio) de cada celda y se ordenan las celdas con vecino más cercano entre centroides. Esto significa que el recorrido visita las celdas en un orden geográficamente razonable, sin saltar de un extremo del mapa al otro.
5. **Unión.** Se concatenan los subtours en ese orden y se obtiene el tour global de 200000 ciudades. Esto significa que las uniones entre celdas son greedy (se pegan tal cual), por lo que se pierde optimalidad global a cambio de hacerlo computable.

Por eso en el CSV la fila de 200000 dice `ants=20, iters=100`: son los valores globales del CLI, pero cada celda corre su propio ACO de ≈ 10 hormigas $\times$ 15–25 iteraciones. Y `-target-cluster 600` significa el tamaño de celda deseado: con un valor menor hay más celdas (más rápido, peor calidad en las uniones); con un valor mayor hay menos celdas (mejor calidad, más memoria y tiempo por celda).

4.7. Complejidad

- Memoria en modo `full`: $O(n^2)$ (matriz de distancias + matriz de feromona).
- Tiempo en modo `full`: $O(t_{\text{máx}} \cdot m \cdot n \cdot k)$ con candidatos.
- Modo `hier`: $O(n)$ en memoria global + ACO sobre celdas de tamaño acotado.

Las hormigas de cada iteración se construyen en paralelo con OpenMP.

5. Punto 3. Implementación y comandos de ejecución

5.1. Estructura del repositorio

- `src/tsp.h`: instancia euclidiana, matriz densa, k-NN exacto.
- `src/aco.h`: solver MMAS + 2-opt.
- `src/main.cpp`: CLI, modos, particionado en rejilla, salida CSV.
- `src/metrics.h`: cronómetro (`chrono`) y pico de RAM (`getrusage`).

- CMakeLists.txt: compilación Release -O3 con OpenMP.
- scripts/run_benchmark.sh: corre los 3 casos y genera results.csv.
- scripts/plot.py: genera img/benchmark.png.

5.2. Compilación

Vía CMake (recomendada):

```
cmake -S . -B build -DCMAKE_BUILD_TYPE=Release
cmake --build build -j$(nproc)
```

Vía manual, sin cmake (un solo comando):

```
g++ -O3 -std=c++17 -fopenmp src/main.cpp -o aco
```

5.3. Comandos de ejecución

```
# 20 ciudades: ACO completo
./build/aco --n 20 --ants 20 --iters 100 --cand 8 \
  --seed 42 --mode full

# 2000 ciudades: ACO completo con 25 candidatos
./build/aco --n 2000 --ants 25 --iters 50 --cand 25 \
  --seed 42 --mode full --out results.csv

# 200000 ciudades: ACO jerárquico (celdas de ~600 puntos)
./build/aco --n 200000 --seed 42 --mode hier \
  --target-cluster 600 --out results.csv

# Benchmark completo + gráfica
bash scripts/run_benchmark.sh
python3 scripts/plot.py results.csv
```

Parámetros: `-n` ciudades, `-ants` hormigas por iteración, `-iters` iteraciones, `-cand` vecinos candidatos (0 = sin lista), `-seed` semilla, `-target-cluster` tamaño de celda en modo `hier`, `-out` archivo CSV, `-no-2opt` desactiva la mejora local.

5.4. Evidencia de ejecución

Figura 1: Salidas reales del programa en local.

```
n=20 mode=full ants=20 iters=100 seed=42 length=4460.31
time_ms=142.6 peak_kb=4452
matrix_mb_est=0.00 (solo modo full)

n=2000 mode=full ants=25 iters=50 seed=42 length=38698.88
time_ms=1218.2 peak_kb=52028
```

```
matrix_mb_est=15.26 (solo modo full)
```

```
[hier] n=200000 G=19 clusters=361  
n=200000 mode=hier ants=20 iters=100 seed=42 length=408901.41  
time_ms=6988.3 peak_kb=74796  
matrix_mb_est=152587.89 (solo modo full)
```

6. Punto 4. Evaluación experimental

6.1. Resultados

Máquina: Arch Linux, 12 núcleos, 14 GB RAM, g++ 16.2.1, OpenMP. Semilla 42 en los tres casos.

Cuadro 4: Desempeño en tiempo y memoria.

n	Modo	Hormigas $\times$ iters	Longitud	Tiempo	Memoria pico
20	full (k=8)	20×100	4460,31	0,14 s	4,4 MB
2000	full (k=25)	25×50	38698,88	1,22 s	52,0 MB
200000	hier (361 celdas)	10×25 por celda	408901,41	6,99 s	75,0 MB




Figura 2: Tiempo, memoria pico y longitud del tour para los tres tamaños.

6.2. Análisis de las gráficas (Figura 2)

La Figura 2 tiene tres diagramas de barras, uno por métrica, con una barra por tamaño (20, 2000 y 200000). Se leen así:

Gráfica 1: Tiempo (s). Las barras crecen de 0,14 s a 1,22 s y a 6,99 s. Esto significa que multiplicar las ciudades por 100 (de 20 a 2000) solo multiplica el tiempo por 9: el crecimiento es subcuadrático gracias a los candidatos. La barra de 200000 (≈ 7 s) es la prueba visual de que el modo jerárquico rompe la barrera del $O(n^2)$: sin él, esa barra ni siquiera podría existir porque el programa no cabría en memoria.

Gráfica 2: Memoria pico (MB). Las barras marcan 4,4 MB, 52 MB y 75 MB. Esto significa dos cosas: entre 20 y 2000 la memoria sí sigue al $O(n^2)$ de las matrices (las barras crecen fuerte), pero entre 2000 y 200000 apenas sube de 52 a 75 MB a pesar de haber $\times 100$ ciudades. Esa segunda transición plana es la huella del diseño jerárquico: la memoria deja de depender de n^2 y pasa a depender de n (el vector de puntos) más celdas de tamaño fijo.

Gráfica 3: Longitud del tour. Las barras crecen (4460, 38699, 408901) simplemente porque hay más ciudades que visitar en el mismo mapa de 1000×1000 . Esto significa que esta gráfica no mide calidad del algoritmo sino tamaño de la instancia: cada barra viene de puntos aleatorios distintos, así que no se puede decir que una configuración sea mejor que otra comparando estas tres barras entre sí.

6.3. Análisis de resultados

a) ¿Cómo escala el tiempo? De 20 a 2000 ciudades ($\times 100$ en n) el tiempo solo sube de 0,14 s a 1,22 s ($\times 9$), gracias a la lista de candidatos: cada paso cuesta $O(k)$ en vez de $O(n)$. El caso de 200000 se resuelve en ≈ 7 s porque el trabajo se divide en 361 ACOs de ≈ 550 puntos (costo casi lineal en n) más el ordenado de centroides $O(C^2)$ con $C = 361$, despreciable. Sin el enfoque jerárquico, un ACO denso en 200000 ciudades sería intratable en tiempo ($O(t_{\text{máx}} \cdot m \cdot n^2)$ por iteración).

b) ¿Cómo escala la memoria? Con $n = 20$ se usan 4,4 MB (sobrecarga base del proceso y los hilos OpenMP; las matrices de 20×20 son insignificantes). Con $n = 2000$ se usan 52 MB: ≈ 15 MB de distancias + ≈ 15 MB de feromona + k-NN y tours de 25 hormigas, coherente con el $O(n^2)$ teórico. Con $n = 200000$ se usan solo 75 MB: nunca se construye la matriz global (que pediría ≈ 149 GB por matriz); cada celda aloja matrices de $\approx 600 \times 600$ ($\approx 1,4$ MB) y el resto es el vector de 200000 puntos. El diseño jerárquico cambia la memoria de $O(n^2)$ a $O(n)$.

c) ¿Qué aportan los candidatos y el 2-opt? Son los que más mejoran la relación calidad/tiempo: los candidatos reducen el paso de $O(n)$ a $O(k)$ y el 2-opt corrige cruces del tour construido por las hormigas. Desactivarlos (-cand 0, -no-2opt) empeora la longitud, el tiempo o ambos.

d) ¿Son comparables las longitudes entre tamaños? No directamente: cada n usa una instancia aleatoria distinta (más ciudades $\Rightarrow$ tour más largo). Para comparar variantes (distinto k , ρ o con/sin 2-opt) hay que fijar el mismo n y -seed y mirar la columna length del CSV.

e) ¿Qué configuración se recomienda? Para miles de ciudades, ACO denso con $k \approx 25$ y 2-opt activado (caso $n = 2000$: 1,2 s y 52 MB). Para cientos de miles, el esquema jerárquico con celdas de ≈ 600 puntos (≈ 7 s y 75 MB), aceptando que la unión greedy de subtours sacrifica optimalidad global. Trabajo futuro: orientar y coser subtours vecinos en vez de concatenar, y 2-opt entre celdas.

6.4. Conclusión de la evaluación experimental

1. El ACO clásico con matriz densa es viable hasta algunos miles de ciudades en local (2000 $\Rightarrow$ 1,2 s, 52 MB).
2. Para 200000 ciudades el ACO puro es inviable por memoria (≈ 149 GB por matriz); el esquema jerárquico lo hace posible en ≈ 7 s y 75 MB.
3. Con la misma semilla, la longitud del tour es reproducible en cualquier máquina; tiempo y memoria solo son comparables dentro de la misma máquina.